

第一次使用必看

PAPERREADINGDESK / FEATURE TOUR

从 PDF 到可复用的论文笔记

按真实使用顺序查看 PaperReadingDesk：先配置本机 Codex，再导入论文，完成图片与公式保留、翻译、双语阅读、AI 阅读笔记和摘录。

本机 AI 配置

本机 Codex 配置

● 配置成功

重新读取

认证方式

ChatGPT 账号

CLI 版本

codex-cli 0.146.1

已保存命令

codex --profile plus

模型

gpt-5.6-sol

推理强度

high

测试返回

CONFIG_OK

配置自己的本机 Codex

先在终端安装 Codex 并登录，再保存并测试下面的配置。

▼新用户：这些值在哪里看？

1. 执行 `codex login status` 确认登录。
2. 执行 `codex`，输入 `/model` 查看模型和推理强度。
3. 输入 `/status` 确认当前选择。

LOCAL CODEX

连接你自己的本机 Codex

在主页保存 Codex 命令、模型和推理强度，并直接检查登录方式、CLI 版本与测试返回。当前 AI 功能仅支持 Codex，配置成功后才会启用。

论文阅读器

论文阅读

拖入英文 PDF，由本机 Codex 翻译，在同一页进行中英对照阅读。



拖拽 PDF 到这里

或点击选择文件 · 单个文件不超过 60 MB

论文库

论文库

全部论文 7 + 文件夹

- 已阅 2 -
- 未读 3 -
- 重要论文 1 -
- 未分类 1

VIEW

全部论文

7

7 / 7

Attention Is All You Need PDF

可阅读 EN ↔ 中文 2.1 MB
翻译耗时 1m 22s · 180,127 tokens

PDF
可阅读 EN ↔ 中文 7.5 MB
翻译耗时 4m 31s · 454,356 tokens

PDF
可阅读 EN ↔ 中文 23.9 MB
翻译耗时 1m 45s · 228,488 tokens

PDF
可阅读 EN ↔ 中文 13.5 MB
翻译耗时 1m 44s · 113,328 tokens

PDF
可阅读 EN ↔ 中文 12.6 MB
翻译耗时 1m 54s · 25,979 tokens

PDF
可阅读 EN ↔ 中文 5.9 MB
翻译耗时 2m 10s · 156,625 tokens

PDF
可阅读 EN ↔ 中文 5.1 MB
翻译耗时 6m 19s · 496,894 tokens

IMPORT & LIBRARY

批量导入并整理论文库

拖入一个或多个 PDF，统一选择自动分析、单栏或双栏版式。论文可放入自建文件夹，并显示阅读状态、文件大小、翻译耗时和 token 使用量。

PIPELINE

目录

Abstract

摘要

1 Introduction

引言

2 Background

背景

3 Model Architecture

模型架构

3.1 Encoder and Decoder Stacks

编码器和解码器堆栈

3.2 Attention

注意力机制

3.2.1 Scaled Dot-Product Attention

缩放点积注意力

3.2.2 Multi-Head Attention

多头注意力

3.2.3 Applications of Attention in our

中英对照阅读

AI 辅助阅读

论文摘要

按住 Ctrl，将鼠标放在英文句子上查看中文

English ↔ 中文

只看英文

只看中文

ENGLISH

中文

Attention Is All You Need

复制完整标题

注意力机制就是你所需要的一切

Ashish Vaswani • Noam Shazeer • Niki Parmar • Jakob Uszkoreit • Google Brain • Google Research • Llion Jones • Aidan N. Gomez • Illia Polosukhin

摘要

The dominant sequence transduction models are based on

当前主流的序列转换模型基于复杂的循环神经网络

BILINGUAL READING

目录、翻译与双语阅读

自动恢复论文标题、摘要和章节目录，提供双语、仅英文、仅译文三种阅读模式。

跳到正文

注意力机制

3.2.1 Scaled Dot-Product Attention
缩放点积注意力

3.2.2 Multi-Head Attention
多头注意力

3.2.3 Applications of Attention in our Model
注意力机制在本模型中的应用

3.3 Position-wise Feed-Forward Networks
逐位置前馈网络

3.4 Embeddings and Softmax
嵌入与 Softmax

3.5 Positional Encoding
位置编码

4 Why Self-Attention
为什么使用自注意力

5 Training
训练

5.1 Training Data and Batching
训练数据与批处理

5.2 Hardware and Schedule

127.0.0.1:8011/papers.html?paper=e6412563-dc8e-422f-a1de-a748a5313f3b&module=reading#mainContent

3.1 Encoder and Decoder Stacks

编码器和解码器堆栈




Figure 1: The Transformer - model architecture.

Figure 1: The Transformer - model architecture.

图 1: Transformer——模型架构。



FIGURES & TABLES

图片、表格与双语图注

将论文中的图片和表格放回相应正文位置，同时保留原图注和译文。若复杂版式导致边界不理想，可用方向按钮手动扩展裁剪范围。

注意力机制

3.2.1 Scaled Dot-Product Attention
缩放点积注意力

3.2.2 Multi-Head Attention
多头注意力

3.2.3 Applications of Attention in our Model
注意力机制在本模型中的应用

3.3 Position-wise Feed-Forward Networks
逐位置前馈网络

3.4 Embeddings and Softmax
嵌入与 Softmax

3.5 Positional Encoding
位置编码

4 Why Self-Attention
为什么使用自注意力

5 Training
训练

5.1 Training Data and Batching
训练数据与批处理

5.2 Hardware and Schedule
硬件与训练计划

We compute the matrix of outputs as: $\text{QK}^T \text{Attention}(\text{Q}, \text{K}, \text{V}) = \text{softmax}(\frac{\text{QK}^T}{\sqrt{d_k}}) \text{V}$

我们按如下方式计算输出矩阵: $\text{QK}^T \text{Attention}(\text{Q}, \text{K}, \text{V}) = \text{softmax}(\frac{\text{QK}^T}{\sqrt{d_k}}) \text{V}$

EQUATION 1

复制公式源码

复制公式源码

$$= \text{softmax}\left(\frac{\text{QK}^T}{\sqrt{d_k}}\right) \text{V}$$

▼ 查看原 PDF 公式

$$= \text{softmax}\left(\frac{\text{QK}^T}{\sqrt{d_k}}\right) \text{V} \tag{1}$$

The two most commonly used attention functions are additive attention [2], and dot-product (multiplicative) attention. Dot-product attention is identical to our algorithm, except for the

最常用的两种注意力函数是加性注意力 [2] 和点积（乘性）注意力。除 $\sqrt{d_k}$ 这一缩放因子外，点积注意力与我们的算法完全相同。加性注意力使用具有 k 单个隐藏层

EQUATIONS

可复制公式与原 PDF 对照

可靠转写的公式以清晰的 LaTeX 重新排版，并可一键复制源码；原 PDF 公式始终可以展开核对，避免只看转写结果而丢失依据。

注意力机制

3.2.1 Scaled Dot-Product Attention
缩放点积注意力

3.2.2 Multi-Head Attention
多头注意力

3.2.3 Applications of Attention in our Model
注意力机制在本模型中的应用

3.3 Position-wise Feed-Forward Networks
逐位置前馈网络

3.4 Embeddings and Softmax
嵌入与 Softmax

3.5 Positional Encoding
位置编码

4 Why Self-Attention
为什么使用自注意力

5 Training
训练

5.1 Training Data and Batching
训练数据与批处理

5.2 Hardware and Schedule
硬件与训练计划

5.3 Optimizer
优化器

中英对照阅读

AI 辅助阅读

论文摘要

AI READING NOTES

按笔记指南生成

按三遍阅读法生成

AI 阅读笔记

每次生成都会保存为一个新版本，不会覆盖旧笔记。

Codex 正在生成新的笔记版本。

版本 2
笔记指南
生成中 · 8月21日 20:15

版本 1
三遍阅读法
生成中 · 8月21日 20:15

HIGHLIGHTS & QUESTIONS

高亮与提问

还没有高亮或问题。选择一段文字开始。

AI ASSISTED READING

AI 阅读笔记、高亮与提问

AI 辅助阅读提供“笔记指南”和“三遍阅读法”两种生成方法，每次生成都会保留新版本。阅读正文时也可以选择片段，围绕原文向 Codex 提问。

AI READING NOTES

AI 阅读笔记

每次生成都会保存为一个新版本，不会覆盖旧笔记。

版本 2
笔记指南
8月21日 20:15

版本 1
三遍阅读法
8月21日 20:15

MARKDOWN 源文件

保存

编译预览

打印 / 导出 PDF

Attention Is All You Need

1. 论文概述：用注意力取代循环与卷积

这是一篇模型方法论文，讨论如何完成**序列转导 (Sequence Transduction)**：模型接收一个符号序列，将其转换为另一个序列，例如把英语句子翻译为德语句子。论文提出 Transformer，其核心判断是：编码器-解码器 (Encoder-Decoder) 模型不必依赖循环神经网络 (Recurrent Neural Network, RNN) 或卷积神经网络 (Convolutional Neural Network, CNN)，仅使用注意力机制也能建立输入、输出各位置之间的依赖。

理解全文需要抓住四个对象：

- **编码器 (Encoder)** **把输入符号序列映射为一组连续表示，供解码器查询。
- **解码器 (Decoder)** **根据编码器表示和已经生成的符号，自回归地预测下一个符号。
- **自注意力 (Self-Attention)** **让一个序列中的每个位置直接汇聚同一序列其他位置的信

Attention Is All You Need

1. 论文概述：用注意力取代循环与卷积

这是一篇模型方法论文，讨论如何完成序列转导 (Sequence Transduction)：模型接收一个符号序列，将其转换为另一个序列，例如把英语句子翻译为德语句子。论文提出 Transformer，其核心判断是：编码器-解码器 (Encoder-Decoder) 模型不必依赖循环神经网络

EDITABLE NOTES

版本化 Markdown 笔记

生成结果不是一次性文本：左侧可直接编辑 Markdown，右侧同步查看排版预览。修改可以保存，也可以打印或导出为 PDF。

同和位置表示中提取信息。

全文的证据链是：先给出完全基于注意力的端到端架构，再从计算复杂度、并行程度和依赖路径长度解释其合理性，最后以机器翻译结果、组件变体实验和英语成分句法分析实验检验质量、效率与任务迁移能力。

2. 任务设定与端到端信息流

给定输入序列 $(x_1, \dots, x_n)$ ，编码器产生连续表示序列 $(z_1, \dots, z_n)$ ；解码器再逐步生成输出 $(y_1, \dots, y_m)$ 。生成是**自回归 (Auto-Regressive)** 的。

▼ 论文图片 · 点击图片插入 Markdown





Table 1: Maximum path lengths, per-layer complexity and minimum number of sequential operations for different layer types. n is the sequence length, d is the dimension.

Layer Type	Max Path Length	Per-layer Complexity	Min Seq. Ops
Self-Attention	$O(n^2)$	$O(n^2 d)$	$O(n^2)$
Multi-Head Attention	$O(n^2)$	$O(n^2 d)$	$O(n^2)$
Feed Forward	$O(n)$	$O(n d)$	$O(n)$

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French news test 2014 tests at a fraction of the cost.

Model	English-to-German BLEU	English-to-French BLEU	Relative Cost
Transformer	28.4	40.6	1.0
Seq2Seq	28.1	40.4	~10x
Seq2Seq+Attn	28.2	40.5	~10x
Seq2Seq+Attn+Relu	28.3	40.5	~10x

Table 3: Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French news test 2014 tests at a fraction of the cost.

Model	English-to-German BLEU	English-to-French BLEU	Relative Cost
Transformer	28.4	40.6	1.0
Seq2Seq	28.1	40.4	~10x
Seq2Seq+Attn	28.2	40.5	~10x
Seq2Seq+Attn+Relu	28.3	40.5	~10x

Table 4: Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French news test 2014 tests at a fraction of the cost.

Model	English-to-German BLEU	English-to-French BLEU	Relative Cost
Transformer	28.4	40.6	1.0
Seq2Seq	28.1	40.4	~10x
Seq2Seq+Attn	28.2	40.5	~10x
Seq2Seq+Attn+Relu	28.3	40.5	~10x

下图左半部分是六层编码器，右半部分是六层解码器。阅读时应重点观察三条信息路径：编码器内部的全局自注意力、解码器内部受因果掩码约束的自注意力，以及从编码器输出进入解码器的编码器-解码器注意力。




Figure 1: The Transformer - model architecture.
Transformer 的编码器-解码器总体架构

3. Transformer 的层级结构

INSERT PAPER VISUALS

点击论文图片插入笔记

笔记编辑器列出当前论文提取出的图片与表格。点击缩略图即可把带图注的 Markdown 图片引用插入笔记，无需手工寻找图片地址。

学习位置嵌入表现近似。

- 自注意力的主要结构优势是 $O(1)$ 的串行操作数和任意位置间 $O(1)$ 的路径长度；主要代价是全局注意力对序列长度具有二次复杂度。
- 翻译结果支持 Transformer 在论文设置下兼具质量和训练效率，组件变体支持多头、足够的键维度、模型容量和正则化的重要性。
- 论文消除了大量训练阶段的顺序计算，但没有消除自回归生成的顺序性；长序列效率、跨模态应用和更并行的生成仍是其明确留下的问题。

![Figure 4: Two attention heads, also in layer 5 of 6, apparently involved in anaphora resolution. Top: Full attentions for head 5. Bottom: Isolated attentions from just the word 'it'](/api/paper-images/376)

▼ 论文图片 · 点击图片插入 Markdown



Table 3: Variations on the Transformer architecture. Unlisted values are identical to those of the base model. ... metrics are on the English-to-German translation.



Table 4: The Transformer generalizes well to English constituency parsing (Results are on Section 23 of WSJ) ... Parser Train on WSJ 123 E1 Vinyals & Kaiser et al. (2014) 1371



Figure 3: An example of the attention mechanism following long-distance dependencies in the encoder self-attention...




Figure 4: Two attention heads, also in layer 5 of 6, apparently involved in anaphora resolution. Top: Full... attentions for head 5. Bottom: Isolated attentions from...

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O.$$

基础模型使用 $h = 8$ 个头，且 $d_k = d_v = d_{model}/h = 64$ 。由于每个头只处理较低维表示，八个头的总计算量与一个完整维度的单头注意力近似。多头的关键价值不是简单增加计算次数，而是允许模型同时关注不同位置和不同表示子空间中的关系。

下图左侧展示“匹配—缩放—归一化—加权求和”，右侧展示多个注意力头如何并行投影、计算并重新拼接。




Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

VISUAL NOTE COMPOSITION

图文一起组织研究笔记

在 Markdown 源文中组织论点、公式和插图，同时通过预览确认最终阅读效果，让论文中的视觉证据真正进入笔记，而不是与文字分离。

AI READING NOTES

AI 阅读笔记

每次生成都会保存为一个新版本，不会覆盖旧笔记。

按笔记指南生成

按三遍阅读法生成

版本 2

笔记指南

8月21日 20:15

版本 1

三遍阅读法

8月21日 20:15

一句话

论文提出 Transformer：一种完全依赖自注意力（Self-Attention）与多头注意力（Multi-Head Attention）、不使用循环或卷积的编码器—解码器（Encoder-Decoder）序列转导（Sequence Transduction）架构；作者报告其训练并行性更强，并在机器翻译和英语成分句法分析中取得有竞争力的结果。

论文类型

方法与神经网络架构论文，主要证据来自受控基准实验、组件变体实验、渐近复杂度分析和少量注意力可视化案例。

研究背景

此前主流序列建模与机器翻译系统采用循环式或卷积式编码器—解码器，注意力通常只是辅助模块。循环模型按位置顺序计算，限制单个样本内部的并行化；卷积模型虽可并行，但连接远距离位置通常需要堆叠多层。论文将 Transformer 定位为首个完全以自注意力计算输入、输出表示且不使用序列对齐循环或卷积的转导模型。

主要贡献

研究问题

能否用完全基于注意力机制（Attention Mechanism）的 Transformer 取代循环神经网络（Recurrent Neural Network, RNN）和卷积神经网络（Convolutional Neural Network），同时提高序列建模的训练并行性、缩短长距离依赖路径，并保持或提升翻译质量？

概要

Transformer 将序列转导改写为由注意力、逐位置前馈网络、残差连接、层归一化和位置编码组成的全并行架构。论文的证据是 WMT 翻译基准和组件变体实验；句法分析提供跨任务证据；复杂度表提供理论动机；注意力图仅提供定性观察。方法与主要超参数描述较清楚，但所给载荷中的表2、表3排版受损，且 English-French 的 41.8 与 41.0 BLEU 相互矛盾。

方法 pipeline


THREE-PASS METHOD

用三遍阅读法拆解论文

三遍阅读法会从一句话结论、论文类型、研究问题与背景开始，继续检查方法、证据、实验可信度和复现线索，适合系统理解与审查论文。

方法来源：S. Keshav, 《How to Read a Paper》，ACM SIGCOMM CCR 37(3), 2007





PAPER CLIPPINGS

独立保存论文摘录

把值得保留的原文、回答或手写内容保存到当前论文。摘录只负责记录与编辑，不会自动生成 AI 阅读笔记，也不会与其他论文混在一起。