

第一次使用必看

PAPERREADINGDESK / FEATURE TOUR

从 PDF 到可复用的论文笔记

按真实使用顺序查看 PaperReadingDesk：先配置本机 AI，再导入论文，完成图片与公式保留、翻译、双语阅读、AI 阅读笔记和摘录。

本机 AI 配置

本机 Codex 配置

● 配置成功

重新读取

认证方式

ChatGPT 账号

CLI 版本

codex-cli 0.146.1

已保存命令

codex --profile plus

模型

gpt-5.6-sol

推理强度

high

测试返回

CONFIG_OK

配置自己的本机 Codex

先在终端安装 Codex 并登录，再保存并测试下面的配置。

▼新用户：这些值在哪里看？

1. 执行 `codex login status` 确认登录。
2. 执行 `codex`，输入 `/model` 查看模型和推理强度。
3. 输入 `/status` 确认当前选择。

LOCAL AI

连接 Codex 或 Claude Code

在主页保存并测试 Codex 或 Claude Code 的命令与模型，再将测试成功的一个设为当前 AI。账号凭据仍由相应 CLI 自己管理。

论文阅读器

论文阅读

拖入英文 PDF，由本机 Codex 翻译，在同一页进行中英对照阅读。



拖拽 PDF 到这里

或点击选择文件 · 单个文件不超过 60 MB

论文库

论文库

全部论文 7 + 文件夹

- 已阅 2 -
- 未读 3 -
- 重要论文 1 -
- 未分类 1

VIEW

全部论文

7

7 / 7

Attention Is All You Need PDF

可阅读 EN ↔ 中文 2.1 MB
翻译耗时 1m 22s · 180,127 tokens

PDF
可阅读 EN ↔ 中文 7.5 MB
翻译耗时 4m 31s · 454,356 tokens

PDF
可阅读 EN ↔ 中文 23.9 MB
翻译耗时 1m 45s · 228,488 tokens

PDF
可阅读 EN ↔ 中文 13.5 MB
翻译耗时 1m 44s · 113,328 tokens

PDF
可阅读 EN ↔ 中文 12.6 MB
翻译耗时 1m 54s · 25,979 tokens

PDF
可阅读 EN ↔ 中文 5.9 MB
翻译耗时 2m 10s · 156,625 tokens

PDF
可阅读 EN ↔ 中文 5.1 MB
翻译耗时 6m 19s · 496,894 tokens

IMPORT & LIBRARY

批量导入并整理论文库

拖入一个或多个 PDF，统一选择自动分析、单栏或双栏版式。论文可放入自建文件夹，并显示阅读状态、文件大小、翻译耗时和 token 使用量。

PIPELINE

目录

Abstract

摘要

1

Introduction

引言

2

Background

背景

3

Model Architecture

模型架构

3.1

Encoder and Decoder Stacks

编码器和解码器堆栈

3.2

Attention

注意力机制

3.2.1

Scaled Dot-Product Attention

缩放点积注意力

3.2.2

Multi-Head Attention

多头注意力

3.2.3

Applications of Attention in our

中英对照阅读

AI 辅助阅读

论文摘要

按住 Ctrl，将鼠标放在英文句子上查看中文

English ↔ 中文

只看英文

只看中文

ENGLISH

中文

Attention Is All You Need

复制完整标题

注意力机制就是你所需要的一切

Ashish Vaswani • Noam Shazeer • Niki Parmar • Jakob Uszkoreit • Google Brain • Google Research • Llion Jones • Aidan N. Gomez • Illia Polosukhin

摘要

The dominant sequence transduction models are based on

当前主流的序列转换模型基于复杂的循环神经网络

BILINGUAL READING

目录、翻译与双语阅读

自动恢复论文标题、摘要和章节目录，提供双语、仅英文、仅译文三种阅读模式。

跳到正文

注意力机制

3.2.1

Scaled Dot-Product Attention
缩放点积注意力

3.2.2

Multi-Head Attention
多头注意力

3.2.3

Applications of Attention in our Model
注意力机制在本模型中的应用

3.3

Position-wise Feed-Forward Networks
逐位置前馈网络

3.4

Embeddings and Softmax
嵌入与 Softmax

3.5

Positional Encoding
位置编码

4

Why Self-Attention
为什么使用自注意力

5

Training
训练

5.1

Training Data and Batching
训练数据与批处理

5.2

Hardware and Schedule

127.0.0.1:8011/papers.html?paper=e6412563-dc8e-422f-a1de-a748a5313f3b&module=reading#mainContent

3.1 Encoder and Decoder Stacks

编码器和解码器堆栈




Figure 1: The Transformer - model architecture.

Figure 1: The Transformer - model architecture.

图 1: Transformer——模型架构。



FIGURES & TABLES

图片、表格与双语图注

将论文中的图片和表格放回相应正文位置，同时保留原图注和译文。若复杂版式导致边界不理想，可用方向按钮手动扩展裁剪范围。

注意力机制

3.2.1 Scaled Dot-Product Attention
缩放点积注意力

3.2.2 Multi-Head Attention
多头注意力

3.2.3 Applications of Attention in our Model
注意力机制在本模型中的应用

3.3 Position-wise Feed-Forward Networks
逐位置前馈网络

3.4 Embeddings and Softmax
嵌入与 Softmax

3.5 Positional Encoding
位置编码

4 Why Self-Attention
为什么使用自注意力

5 Training
训练

5.1 Training Data and Batching
训练数据与批处理

5.2 Hardware and Schedule
硬件与训练计划

We compute the matrix of outputs as: $\text{QK}^T \text{Attention}(\text{Q}, \text{K}, \text{V}) = \text{softmax}(\frac{\text{QK}^T}{\sqrt{d_k}}) \text{V}$

我们按如下方式计算输出矩阵: $\text{QK}^T \text{Attention}(\text{Q}, \text{K}, \text{V}) = \text{softmax}(\frac{\text{QK}^T}{\sqrt{d_k}}) \text{V}$

EQUATION 1

复制公式源码

复制公式源码

$$= \text{softmax}\left(\frac{\text{QK}^T}{\sqrt{d_k}}\right) \text{V}$$

▼ 查看原 PDF 公式

$$= \text{softmax}\left(\frac{\text{QK}^T}{\sqrt{d_k}}\right) \text{V} \tag{1}$$

The two most commonly used attention functions are additive attention [2], and dot-product (multiplicative) attention. Dot-product attention is identical to our algorithm, except for the

最常用的两种注意力函数是加性注意力 [2] 和点积（乘性）注意力。除 $\sqrt{d_k}$ 这一缩放因子外，点积注意力与我们的算法完全相同。加性注意力使用具有 k 单个隐藏层

EQUATIONS

可复制公式与原 PDF 对照

可靠转写的公式以清晰的 LaTeX 重新排版，并可一键复制源码；原 PDF 公式始终可以展开核对，避免只看转写结果而丢失依据。

注意力机制

3.2.1

Scaled Dot-Product Attention
缩放点积注意力

3.2.2

Multi-Head Attention
多头注意力

3.2.3

Applications of Attention in our Model
注意力机制在本模型中的应用

3.3

Position-wise Feed-Forward Networks
逐位置前馈网络

3.4

Embeddings and Softmax
嵌入与 Softmax

3.5

Positional Encoding
位置编码

4

Why Self-Attention
为什么使用自注意力

5

Training
训练

5.1

Training Data and Batching
训练数据与批处理

5.2

Hardware and Schedule
硬件与训练计划

5.3

Optimizer
优化器

<

中英对照阅读

AI 辅助阅读

论文摘要

AI READING NOTES

按笔记指南生成

按三遍阅读法生成

AI 阅读笔记

每次生成都会保存为一个新版本，不会覆盖旧笔记。

Codex 正在生成新的笔记版本。

版本 2
笔记指南
生成中 · 8月21日 20:15

版本 1
三遍阅读法
生成中 · 8月21日 20:15

HIGHLIGHTS & QUESTIONS

高亮与提问

还没有高亮或问题。选择一段文字开始。

AI ASSISTED READING

AI 阅读笔记、高亮与提问

AI 辅助阅读提供“笔记指南”和“三遍阅读法”两种生成方法，每次生成都会保留新版本。阅读正文时也可以选择片段，围绕原文向当前 AI 提问。

AI READING NOTES

AI 阅读笔记

每次生成都会保存为一个新版本，不会覆盖旧笔记。

版本 2
笔记指南
8月21日 20:15

版本 1
三遍阅读法
8月21日 20:15

MARKDOWN 源文件

保存

编译预览

打印 / 导出 PDF

Attention Is All You Need

1. 论文概述：用注意力取代循环与卷积

这是一篇模型方法论文，讨论如何完成**序列转导 (Sequence Transduction)**：模型接收一个符号序列，将其转换为另一个序列，例如把英语句子翻译为德语句子。论文提出 Transformer，其核心判断是：编码器-解码器 (Encoder-Decoder) 模型不必依赖循环神经网络 (Recurrent Neural Network, RNN) 或卷积神经网络 (Convolutional Neural Network, CNN)，仅使用注意力机制也能建立输入、输出各位置之间的依赖。

理解全文需要抓住四个对象：

- **编码器 (Encoder)** 把输入符号序列映射为一组连续表示，供解码器查询。
- **解码器 (Decoder)** 根据编码器表示和已经生成的符号，自回归地预测下一个符号。
- **自注意力 (Self-Attention)** 让一个序列中的每个位置直接汇聚同一序列其他位置的信

Attention Is All You Need

1. 论文概述：用注意力取代循环与卷积

这是一篇模型方法论文，讨论如何完成序列转导 (Sequence Transduction)：模型接收一个符号序列，将其转换为另一个序列，例如把英语句子翻译为德语句子。论文提出 Transformer，其核心判断是：编码器-解码器 (Encoder-Decoder) 模型不必依赖循环神经网络

EDITABLE NOTES

版本化 Markdown 笔记

生成结果不是一次性文本：左侧可直接编辑 Markdown，右侧同步查看排版预览。修改可以保存，也可以打印或导出为 PDF。

同时位置表示中提供信息。

全文的证据链是：先给出完全基于注意力的端到端架构，再从计算复杂度、并行程度和依赖路径长度解释其合理性，最后以机器翻译结果、组件变体实验和英语成分句法分析实验检验质量、效率与任务迁移能力。

2. 任务设定与端到端信息流

给定输入序列 $(x_1, \dots, x_n)$ ，编码器产生连续表示序列 $(z_1, \dots, z_n)$ ；解码器再逐步生成输出 $(y_1, \dots, y_m)$ 。生成是**自回归 (Auto-Regressive)** 的。

▼ 论文图片 · 点击图片插入 Markdown





Table 1: Maximum path lengths, per-layer complexity and minimum number of sequential operations for different layer types. n is the sequence length, d is the dimension.

Layer Type	Max Path Length	Per-layer Complexity	Min Seq. Ops
Self-Attention	$O(n^2)$	$O(n^2 d)$	$O(n^2)$
Multi-Head Attention	$O(n^2)$	$O(n^2 d)$	$O(n^2)$
Feed Forward	$O(n)$	$O(n d)$	$O(n)$

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest 2014 tests at a fraction of the cost.

Model	English-to-German BLEU	English-to-French BLEU	Relative Cost
Transformer	28.4	40.6	1.0
Seq2Seq	28.1	40.4	~10x
Seq2Seq+Attn	28.2	40.5	~10x
Seq2Seq+Attn+FF	28.3	40.5	~10x

Table 3: Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest 2014 tests at a fraction of the cost.

Model	English-to-German BLEU	English-to-French BLEU	Relative Cost
Transformer	28.4	40.6	1.0
Seq2Seq	28.1	40.4	~10x
Seq2Seq+Attn	28.2	40.5	~10x
Seq2Seq+Attn+FF	28.3	40.5	~10x

Table 4: Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest 2014 tests at a fraction of the cost.

Model	English-to-German BLEU	English-to-French BLEU	Relative Cost
Transformer	28.4	40.6	1.0
Seq2Seq	28.1	40.4	~10x
Seq2Seq+Attn	28.2	40.5	~10x
Seq2Seq+Attn+FF	28.3	40.5	~10x

下图左半部分是六层编码器，右半部分是六层解码器。阅读时应重点观察三条信息路径：编码器内部的全局自注意力、解码器内部受因果掩码约束的自注意力，以及从编码器输出进入解码器的编码器-解码器注意力。




Figure 1: The Transformer - model architecture.
Transformer 的编码器-解码器总体架构

3. Transformer 的层级结构

INSERT PAPER VISUALS

点击论文图片插入笔记

笔记编辑器列出当前论文提取出的图片与表格。点击缩略图即可把带图注的 Markdown 图片引用插入笔记，无需手工寻找图片地址。

学习位置嵌入表现近似。

- 自注意力的主要结构优势是 $O(1)$ 的串行操作数和任意位置间 $O(1)$ 的路径长度；主要代价是全局注意力对序列长度具有二次复杂度。
- 翻译结果支持 Transformer 在论文设置下兼具质量和训练效率，组件变体支持多头、足够的键维度、模型容量和正则化的重要性。
- 论文消除了大量训练阶段的顺序计算，但没有消除自回归生成的顺序性；长序列效率、跨模态应用和更并行的生成仍是其明确留下的问题。

![Figure 4: Two attention heads, also in layer 5 of 6, apparently involved in anaphora resolution. Top: Full attentions for head 5. Bottom: Isolated attentions from just the word 'it'](/api/paper-images/376)

▼ 论文图片 · 点击图片插入 Markdown



Table 3: Variations on the Transformer architecture. Unlisted values are identical to those of the base model. ... metrics are on the English-to-German translation.



Table 4: The Transformer generalizes well to English constituency parsing (Results are on Section 23 of WSJ) ... Parser Train on WSJ 123 E1 Vinyals & Kaiser et al. (2014) [37]



Figure 3: An example of the attention mechanism following long-distance dependencies in the encoder self-attention...




Figure 4: Two attention heads, also in layer 5 of 6, apparently involved in anaphora resolution. Top: Full... attentions for head 5. Bottom: Isolated attentions from...

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O.$$

基础模型使用 $h = 8$ 个头，且 $d_k = d_v = d_{\text{model}}/h = 64$ 。由于每个头只处理较低维表示，八个头的总计算量与一个完整维度的单头注意力近似。多头的关键价值不是简单增加计算次数，而是允许模型同时关注不同位置和不同表示子空间中的关系。

下图左侧展示“匹配—缩放—归一化—加权求和”，右侧展示多个注意力头如何并行投影、计算并重新拼接。




Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

VISUAL NOTE COMPOSITION

图文一起组织研究笔记

在 Markdown 源文中组织论点、公式和插图，同时通过预览确认最终阅读效果，让论文中的视觉证据真正进入笔记，而不是与文字分离。

AI READING NOTES

AI 阅读笔记

每次生成都会保存为一个新版本，不会覆盖旧笔记。

按笔记指南生成

按三遍阅读法生成

版本 2

笔记指南

8月21日 20:15

版本 1

三遍阅读法

8月21日 20:15

一句话

论文提出 Transformer：一种完全依赖自注意力（Self-Attention）与多头注意力（Multi-Head Attention）、不使用循环或卷积的编码器—解码器（Encoder-Decoder）序列转导（Sequence Transduction）架构；作者报告其训练并行性更强，并在机器翻译和英语成分句法分析中取得有竞争力的结果。

论文类型

方法与神经网络架构论文，主要证据来自受控基准实验、组件变体实验、渐近复杂度分析和少量注意力可视化案例。

研究背景

此前主流序列建模与机器翻译系统采用循环式或卷积式编码器—解码器，注意力通常只是辅助模块。循环模型按位置顺序计算，限制单个样本内部的并行化；卷积模型虽可并行，但连接远距离位置通常需要堆叠多层。论文将 Transformer 定位为首个完全以自注意力计算输入、输出表示且不使用序列对齐循环或卷积的转导模型。

主要贡献

研究问题

能否用完全基于注意力机制（Attention Mechanism）的 Transformer 取代循环神经网络（Recurrent Neural Network, RNN）和卷积神经网络（Convolutional Neural Network），同时提高序列建模的训练并行性、缩短长距离依赖路径，并保持或提升翻译质量？

概要

Transformer 将序列转导改写为由注意力、逐位置前馈网络、残差连接、层归一化和位置编码组成的全并行架构。论文的强证据是 WMT 翻译基准和组件变体实验；句法分析提供跨任务证据；复杂度表提供理论动机；注意力图仅提供定性观察。方法与主要超参数描述较清楚，但所给载荷中的表2、表3排版受损，且 English-French 的 41.8 与 41.0 BLEU 相互矛盾。

方法 pipeline


THREE-PASS METHOD

用三遍阅读法拆解论文

三遍阅读法会从一句话结论、论文类型、研究问题与背景开始，继续检查方法、证据、实验可信度和复现线索，适合系统理解与审查论文。

方法来源：S. Keshav, 《How to Read a Paper》，ACM SIGCOMM CCR 37(3), 2007





PAPER CLIPPINGS

独立保存论文摘录

把值得保留的原文、回答或手写内容保存到当前论文。摘录只负责记录与编辑，不会自动生成 AI 阅读笔记，也不会与其他论文混在一起。